

Доклад к защите

Введение

Уважаемые председатель и члены государственной аттестационной комиссии!

Вашему вниманию представляется выпускная квалификационная работа на тему «Интеллектуальный анализ на основе LLM».

Цифровая трансформация российской экономики, реализуемая в рамках национальной программы «Цифровая экономика Российской Федерации», выдвинула на первый план задачи автоматизации обработки больших объемов неструктурированной текстовой информации. Крупные языковые модели стали ключевым инструментом решения этих задач в государственном управлении, промышленности, образовании и здравоохранении.

Однако события 2022 года, связанные с блокировкой доступа российских пользователей к ведущим зарубежным платформам искусственного интеллекта, таким как GPT-4, Claude и Gemini, создали критическую ситуацию для организаций, использовавших эти технологии. Указ Президента Российской Федерации номер 166 от тридцатого марта 2022 года о мерах по обеспечению технологической независимости поставил задачу импортозамещения в области искусственного интеллекта на уровень государственной важности.

Одновременно требования ФСТЭК России и Федерального закона 152 «О персональных данных» накладывают жесткие ограничения на использование облачных сервисов иностранных вендоров для обработки информации ограниченного доступа. Это делает разработку отечественных решений на базе больших языковых моделей не вопросом технологических предпочтений, а вопросом обеспечения непрерывности критически важных бизнес-процессов и соблюдения нормативных требований.

Актуальность и практическая значимость

Актуальность исследования определяется несколькими факторами.

Во-первых, существует острый дефицит методических рекомендаций по интеграции отечественных крупных языковых моделей в прикладные системы с учетом требований российских регуляторов. Теоретические основы трансформерных архитектур хорошо освещены в работах ИСП РАН и МФТИ, однако прикладные аспекты адаптации для узкоспециализированных задач остаются малоизученными.

Во-вторых, государственные органы и коммерческие организации, работающие с персональными данными, не могут использовать зарубежные облачные сервисы из-за требований ФЗ-152 о локализации данных на территории России. При этом локальное развертывание крупных языковых моделей требует специфических компетенций и вычислительных ресурсов.

В-третьих, экономическая целесообразность импортозамещения подтверждается высокой стоимостью зарубежных решений. Подписка на GPT-4 API для крупной организации может достигать 15–20 миллионов рублей ежегодно, тогда как использование открытых российских моделей с локальным развертыванием сокращает эти расходы до уровня закупки вычислительных мощностей.

Практическая значимость работы заключается в создании функционального программного модуля для автоматизации обработки обращений граждан в системе регионального органа исполнительной власти. Модуль интегрирован с государственными информационными системами Directum RX и ЕСИА, развернут на отечественном программно-аппаратном комплексе с операционной системой Astra Linux и СУБД PostgresPro. Система прошла трехмесячное пилотное внедрение, показав среднюю оценку качества работы четыре целых две десятых балла из пяти и отсутствие критических сбоев.

Экономический эффект от внедрения составляет более семи миллионов рублей ежегодно за счет сокращения численности операторов с шестнадцати

целых четырех десятых до четырех целых двух десятых штатных единиц при одновременном повышении точности категоризации обращений с семидесяти пяти до девяноста одного процента.

Цель и задачи исследования

Целью выпускной квалификационной работы является разработка интеллектуального аналитического модуля на базе отечественных больших языковых моделей для автоматизации обработки неструктурированной текстовой информации в условиях требований технологического суверенитета Российской Федерации.

Для достижения поставленной цели решались следующие задачи.

Первая задача — изучение генезиса высокоуровневых нейросетевых моделей в работах российских научных школ и требований регуляторов к внедрению искусственного интеллекта в критическую информационную инфраструктуру. В ходе решения этой задачи был проведен анализ развития технологий обработки естественного языка в России от символьных систем семидесятых-восемидесятых годов до современных трансформерных архитектур, а также систематизированы требования ФСТЭК и Минцифры.

Вторая задача — проведение анализа отечественного рынка крупных языковых моделей и средств разработки. Выявлено три основных сегмента рынка: коммерческие облачные платформы YandexGPT и GigaChat, открытые модели ruGPT и OpenGPT, корпоративные решения типа «Искусственный интеллект 360» от Ростелекома. Также проанализированы функциональные дефициты зарубежных систем для российского рынка.

Третья задача — разработка технического задания на программный продукт согласно ГОСТ 34.601-90 и ГОСТ 34.602-89. Техническое задание установило четкие критерии приемки системы и детализировало требования к математическому, информационному, программному и техническому обеспечению.

Четвертая задача — проектирование алгоритмического обеспечения процессов fine-tuning и prompt-инженерии для специализированных задач. Разработана гибридная архитектура, комбинирующая дообученную модель ruBERT для классификации и извлечения сущностей с генеративной моделью GigaChat для формирования ответов.

Пятая задача — реализация интерфейса и интеграционных шлюзов с использованием стека Python и отечественных СУБД. Система реализована в виде микросервисной архитектуры на фреймворке FastAPI с использованием PostgresPro и Redis.

Шестая задача — оценка технико-экономической эффективности внедрения и перспектив масштабирования решения в среде российских операционных систем.

Краткое содержание дипломной работы

Работа состоит из введения, трех глав основной части, заключения и списка использованной литературы.

Первая глава посвящена концептуальным аспектам применения больших языковых моделей в национальных проектах цифровизации. В разделе один целых один рассмотрен генезис высокоуровневых нейросетевых моделей в исследованиях ИСП РАН и ИППИ РАН. Показано, что за период 2022–2025 годов Россия прошла путь от полной зависимости в области LLM до формирования собственной экосистемы с десятком конкурентоспособных моделей. В разделе один целых два проанализированы требования регуляторов Минцифры и ФСТЭК к внедрению технологий искусственного интеллекта в критическую информационную инфраструктуру. Раздел один целых три описывает методологию интеллектуального анализа неструктурированных данных на основе семантических векторов.

Вторая глава содержит аналитическую оценку инфраструктурных решений для интеллектуальных систем. Раздел два целых один представляет

обзор текущего состояния отечественного рынка больших языковых моделей и средств разработки для прикладного программирования. Установлено, что рынок за три года трансформировался из сегмента экспериментальных разработок в полноценную коммерческую отрасль объемом около восемнадцати-двадцати двух миллиардов рублей ежегодно. В разделе два целых два проанализированы функциональные дефициты и риски при эксплуатации зарубежных систем анализа данных в Российской Федерации. В разделе два целых три описано формирование технического задания на разработку программного продукта согласно ГОСТ 34.601-90.

Третья глава раскрывает программную инженерию и практическое внедрение интеллектуального аналитического модуля. Раздел три целых один описывает алгоритмическое обеспечение процессов fine-tuning и prompt-инженерии для специализированных отраслевых задач. Показано, что комбинированное применение дообучения модели `ruBERT` для классификации сорока семи категорий обращений и prompt-инженерии с методом RAG для генерации ответов обеспечивает достижение целевых метрик качества при приемлемых вычислительных затратах. Раздел три целых два посвящен разработке интерфейса и интеграционных шлюзов с использованием стека Python и отечественных СУБД. Раздел три целых три содержит оценку технико-экономической эффективности внедрения и перспектив масштабирования решения в среде российских операционных систем.

Основные результаты

Основные результаты выпускной квалификационной работы состоят в следующем.

Первый результат — создан работающий прототип системы интеллектуального анализа текстовых данных на базе отечественных крупных языковых моделей, соответствующий требованиям ФСТЭК России и ФЗ-152 о персональных данных. Система развернута на отечественной операционной

системе Astra Linux с использованием СУБД PostgresPro и интегрирована с государственными информационными системами через ЕСИА и Directum RX.

Второй результат — разработано алгоритмическое обеспечение, включающее дообученную модель ruBERT для классификации обращений граждан по сорока семи категориям с точностью девяносто одна целых две десятых процента и модель для извлечения именованных сущностей с F1-мерой ноль целых девяносто три сотых. Для генерации проектов ответов применена модель GigaChat с архитектурой RAG, обеспечивающая восемьдесят четыре процента ответов, пригодных к использованию без существенных правок.

Третий результат — экспериментально подтверждена эффективность гибридной архитектуры с динамическим переключением между моделями различной емкости в зависимости от сложности запроса. Такой подход снижает вычислительные затраты на тридцать-сорок процентов по сравнению с использованием единой тяжелой модели для всех операций.

Четвертый результат — проведено пилотное внедрение системы в органе исполнительной власти субъекта Российской Федерации. За три месяца эксплуатации обработано более десяти тысяч обращений граждан со средней оценкой качества автоматически сгенерированных ответов четыре целых две десятых балла из пяти. Критических сбоев, приводящих к потере данных или недоступности системы более пяти минут, не зарегистрировано.

Пятый результат — рассчитана технико-экономическая эффективность внедрения. Рентабельность инвестиций составила триста шестьдесят восемь процентов, срок окупаемости — восемь месяцев, чистый экономический эффект за три года — семнадцать миллионов двести шестьдесят пять тысяч рублей при совокупных затратах четыре миллиона шестьсот девяносто четыре тысячи рублей. Сокращение трудозатрат на обработку обращений составило семьдесят четыре процента при одновременном повышении точности категоризации на шестнадцать процентных пунктов.

Шестой результат — разработана методика комбинированного применения fine-tuning для задач с достаточным объемом размеченных данных и prompt-инженерии для задач, требующих адаптивности к изменяющимся требованиям. Для редких категорий обращений с недостаточным объемом обучающей выборки применен метод few-shot learning, повысивший точность классификации с ноль целых семьдесят девять сотых до ноль целых восемьдесят шесть сотых F1-меры.

Седьмой результат — обоснованы перспективы масштабирования решения на федеральный уровень. Унификация процессов обработки обращений на уровне семидесяти-восемидесяти процентов между регионами позволяет использовать базовую версию модели с минимальной адаптацией через fine-tuning на региональных данных объемом пять-десять тысяч примеров, что занимает два-три часа обучения на одной GPU.

Выводы и предложения

На основании проведенного исследования и полученных результатов можно сделать следующие выводы.

Первый вывод: за период 2022–2025 годов российская ИТ-отрасль сформировала полноценную экосистему крупных языковых моделей, способную закрыть семьдесят-восемьдесят процентов потребностей корпоративного и государственного секторов. Основные игроки — Яндекс, Сбер, Ростелеком — предлагают коммерчески зрелые продукты с документированными API и технической поддержкой на русском языке.

Второй вывод: нормативно-правовая база, включающая Ф3-152, Ф3-187, требования ФСТЭК и Минцифры, создает жесткие ограничения для использования зарубежных облачных систем искусственного интеллекта в критической информационной инфраструктуре. Эти ограничения фактически формируют закрытый рынок, доступный только отечественным разработчикам,

прошедшим процедуру включения в реестр российского программного обеспечения.

Третий вывод: гибридная архитектура, комбинирующая специализированные компактные модели для первичной обработки и тяжелые генеративные модели для финальной обработки отобранных фрагментов, обеспечивает оптимальное соотношение качества и вычислительных затрат. Применение метода RAG снижает долю галлюцинаций больших языковых моделей с восьми целых двух десятых до двух целых семи десятых процента.

Четвертый вывод: экономическая эффективность внедрения систем интеллектуального анализа на базе отечественных LLM подтверждается высокой рентабельностью инвестиций и коротким сроком окупаемости. Основным источником эффекта — кратное сокращение трудозатрат операторов при повышении качества и скорости обработки информации.

Пятый вывод: технологический стек на основе Python, PyTorch, Transformers, LangChain в сочетании с отечественными компонентами PostgresPro и Astra Linux обеспечивает достаточную зрелость для создания продуктивных систем искусственного интеллекта. Развертывание на российских операционных системах не создает критических технических препятствий.

На основании полученных выводов можно сформулировать следующие предложения.

Первое предложение: рекомендуется тиражирование разработанного решения на другие регионы Российской Федерации с организацией централизованной технической поддержки и обучения персонала. Гибридная архитектура с централизованным обучением моделей и распределенным инференсом в регионах соответствует стратегии Минцифры по созданию федеральной платформы искусственного интеллекта.

Второе предложение: целесообразно продолжить исследования в направлении разработки методов автоматического обнаружения и

корректировки галлюцинаций больших языковых моделей в режиме реального времени. Это повысит надежность систем при использовании в критически важных процессах принятия решений.

Третье предложение: необходима стандартизация форматов API отечественных крупных языковых моделей для обеспечения совместимости с де-факто стандартом OpenAI API, что упростит миграцию существующих систем на российские платформы.

Четвертое предложение: рекомендуется развитие специализированных моделей, обученных на корпусах российских нормативно-правовых актов, медицинских протоколов, технической документации для повышения точности работы в узких предметных областях.

Таким образом, выполненная выпускная квалификационная работа подтверждает возможность создания конкурентоспособных систем интеллектуального анализа данных на базе отечественных технологий искусственного интеллекта в условиях требований технологического суверенитета Российской Федерации.

Доклад окончен. Благодарю за внимание и готов ответить на ваши вопросы.